

Projeto Orientado em Computação I

Proposta de Trabalho

Otimização de Handover em Constelações de Satélites via Aprendizado por Reforço: Uma Abordagem Trace-Driven para Redes 6G

Lucas Santana do Carmo Sacramento

Orientador: Luiz Filipe Menezes Vieira

Universidade Federal de Minas Gerais
Departamento de Ciência da Computação

Belo Horizonte, MG, Brasil

1 Introdução

A integração de Redes via satélite é um pilar fundamental da sexta geração de conexão (6G), visando a cobertura global ininterrupta. Constelações de satélites Low Earth Orbit (**LEO**), que operam a aproximadamente 550km, oferecem baixa latência, mas impõe o desafio de handovers frequentes (a cada 2 a 5 minutos) devido à alta velocidade orbital (7,6 km/s)[1]. Estratégias convencionais falham em cenários densos por não considerarem o tempo de serviço remanescente e o impacto dinâmico na carga de rede[2]. Esta proposta apresenta um sistema de handover inteligente utilizando Aprendizado por Reforço Profundo (DRL) baseado em uma metodologia de simulação **Trace-Driven**, otimizando o custo computacional e a fidelidade dos dados[3].




Figura 1: Estrutura da rede de satélites LEO e representação do cenário de handover entre múltiplos usuários terrestres.[4]

Diferente das redes terrestres, o handover em redes LEO é impulsionado pelo movimento rápido e determinístico do satélite. Em exemplos como a rede Starlink, a densidade de satélites permite que um terminal veja dezenas de candidatos simultaneamente, exigindo decisões proativas. A integração em tempo real entre simuladores de órbita e de rede (como o ns-3) pode gerar gargalos no treinamento do modelo. Para contornar possíveis problemas, o projeto irá utilizar uma abordagem **Trace-Driven**: Consiste em extrair métricas de órbita e rede em datasets estáticos antes do treinamento, permitindo que o agente de Reinforcement Learning (RL) aprenda com dados de alta fidelidade sem a sobrecarga de execução simultânea do simulador e do treinamento do modelo de IA.




Figura 2: Arquitetura da rede neural profunda Deep Q-Network (DQN) proposta.

1.1 Objetivos

Desenvolver um algoritmo de handover baseado em Deep Q-Network (DQN) que utilize trajetórias reais de satélites e métricas de rede pré-computadas para otimizar a continuidade da conexão.

1.1.1 Objetivos Específicos

- Gerar um dataset de trajetórias em python usando a biblioteca **Skyfield** e dados TLE completos da base de dados de satélites da Starlink.[5]
- Extrair métricas de rede (latência e throughput) do **ns-3** para diferentes perfis de elevação/distância em uma área delimitada utilizando o módulo **Hypatia**[6]. Criando uma tabela de busca (Lookup Table) com paridade com o dataset de trajetória para o ambiente de RL.
- Implementar o ambiente Gymnasium no modo offline, onde cada passo de tempo consome uma linha do dataset pré-gerado.[7]
- Desenvolver e treinar uma rede neural convolucional para selecionar o satélite ideal com base na estabilidade do link e carga da rede.[2]

1.1.2 contribuições Esperadas

Espera-se demonstrar que a abordagem offline reduz o tempo de treinamento da IA, mantendo a precisão na redução de handovers desnecessários[2]. O projeto entregará um framework para simulação rápida para constelações que utilizam a conexão 6G.

2 Referencial Teórico

- **Constelação Starlink:** Órbitas a 550km com inclinação de 53°. Estudos indicam reconfigurações de feixe em ciclos de 15 segundos, o que gera volatilidade na latência.[8]
- **Mecânica Orbital e TLE:** Os Elementos de Duas Linhas (TLE), são vitais para prever o "Tempo de Serviço Remanescente"(V), permitindo decisões proativas de handover. [9]
- **Deep Q-Learning (DQN):** O agente utiliza redes neurais Conv2D para extrair características espaciais de uma matriz de estado $\phi(s)$ que representa a topologia dinâmica da constelação. [2]

3 Metodologia

3.1 Descrição Geral

3.1.1 Geração de Trajetórias (Python/Skyfield)

Utilizando os dados de localização e TLE obtidos via API do Kaggle possuindo como fonte o **CelesTrak**, será criado um script em Python para propagar as órbitas dos satélites Starlink. O resultado será um CSV contendo:

- Timestamp, Satellite_ID, Elevation, Distance, Remaining_Service_Time (calculado até o cruzamento do horizonte de 25°).

3.1.2 Mapeamento de Rede (ns-3)

Em vez de rodar o ns-3 durante a etapa de RL, ele será usado para gerar um perfil de performance de link em uma determinada região de ação dos satélites.

- Simular no **ns-3** a qualidade da conexão para diversas distâncias (Range) e elevações.
- Gerar um **Lookup Table** que mapeia (Range, elevação) $\rightarrow$ (Latência Média, Perda de Pacotes, Throughput).

3.1.3 Ambiente de RL e Treinamento (Gymnasium)

O ambiente será configurado para ler o CSV da etapa de "Geração de Trajetórias" e consultar a Lookup Table da etapa de "Mapeamento de Rede".

- **Estado** (S_t) Matriz onde cada linha é um satélite visível e as colunas são:

{ Visibilidade, TempoRemanescente, LatênciaEstimada, Carga }.

- **Recompensa** (R_t):

$$R_t = w_0(Estabilidade) + w_1(qualidade) - CustoHandover$$

Onde a estabilidade é o tempo remanescente e a qualidade proveniente da Lookup Table.

4 Resultados Esperados

1. **Dataset de Performance:** Um conjunto de dados que correlaciona geometria orbital com métricas 6G de rede. [10]
2. **Redução de Handovers:** Diminuição nas trocas de sinal em algo em torno de 20% em comparação ao método de "Sinal Mais Forte".
3. **Convergência Rápida:** Demonstração de que o modelo de treinamento do modelo de forma offline converge para uma política ótima com menor gasto de memória e CPU.

5 Cronograma

Tabela 1: Cronograma de Atividades do Projeto

Semana	Atividade Principal	Tarefas Detalhadas
1	Setup do Sistema	Instalação do ns-3 e configuração do Python/Skyfield.
2	Coleta dos Dados e Simulação	Coleta dos dados TLEs; Rodar testes no simulador com exemplos de satélites.
3	Dataset de Trajetória	Geração do CSV Trajetórias com dados TLE; Criação do modelo de mobilidade.
4	Criação da Tabela de Lookup	Geração do CSV dos dados de trajetória e simulados pelo ns-3.
5	Lookup Table de Rede	Mapeamento da performance de link; Criação da tabela de rede para treinamento.
6	Arquitetura e Treino	Implementação do DQN Convolutacional para treinamento offline dos datasets gerados.
7	Treinamento do Modelo	Treinamento do modelo e ajuste dos parâmetros da rede neural.
8	Validação dos Resultados	Comparação com resultados gerados pelo simulador e métodos encontrados na literatura.
9	Escrita da Monografia	Geração de gráficos e análises dos resultados; Escrita da monografia.

Referências

- [1] Nitinder Mohan, Andrew E. Ferguson, Hendrik Cech, Rohan Bose, Prakita Rayyan Renatin, Mahesh K. Marina, and Jörg Ott. A multifaceted look at starlink performance. In *Proceedings of the ACM Web Conference 2024*, WWW '24, page 2723–2734, New York, NY, USA, 2024. Association for Computing Machinery.
- [2] Jie Wang, Weiqing Mu, Yanan Liu, Lantu Guo, Shaofeng Zhang, and Guan Gui. Deep reinforcement learning-based satellite handover scheme for satellite communications. In *2021 13th International Conference on Wireless Communications and Signal Processing (WCSP)*, pages 1–6. IEEE, 2021.
- [3] Martin Ottens, Kai-Steffen Hielscher, and Reinhard German. Trace-driven path emulation of satellite networks using hypatia, 2025.
- [4] Kai Yang, Yichen Wang, Xiaozheng Gao, Chenrui Shi, Yuting Huang, Hang Yuan, and Minwei Shi. Communications in space–air–ground integrated networks: An overview. *Space: Science & Technology*, 5:0199, 2025.
- [5] Vijay J0shi. Starlink satellite tle/csv dataset (april 2025). <https://www.kaggle.com/datasets/vijayj0shi/starlink-satellite-tlecsv-dataset-april-2025/data>, 2025. Version 1.
- [6] Simon Kassing, Debopam Bhattacharjee, André Baptista Águas, Jens Eirik Saethre, and Ankit Singla. Exploring the “Internet from space” with Hypatia. In *ACM IMC*, 2020.
- [7] Zhixin Guo, Qi Shi, Xiaofan Xu, Sixiang Shan, Limin Qin, Linqiang Ge, Rui Zhang, Ya Dai, Hua Zhu, and Guowei Jiang. Spacetrack-timeseries: Time series dataset towards satellite orbit analysis. *arXiv preprint arXiv:2506.13034*, 2025.
- [8] Jonathan C. McDowell. The low earth orbit satellite population and impacts of the spacex starlink constellation. *The Astrophysical Journal Letters*, 892(2):L36, apr 2020.
- [9] Dominic Laniewski, Eric Lanfer, and Nils Aschenbruck. Measuring mobile starlink performance: A comprehensive look. *IEEE Open Journal of the Communications Society*, 2025.
- [10] Hao Wu, Yizhan Han, Mohit Rajpal, Qizhen Zhang, and Jingxian Wang. Sate: Low-latency traffic engineering for satellite networks. In *Proceedings of the ACM SIGCOMM 2025 Conference*, SIGCOMM '25, page 896–916, New York, NY, USA, 2025. Association for Computing Machinery.