

Projeto Orientado em Computação II
Proposta de Trabalho

Otimização de Handover em Constelações de Satélites via Aprendizado por Reforço: Uma Abordagem Trace-Driven para Redes 6G

Lucas Santana do Carmo Sacramento
Orientador: Luiz Filipe Menezes Vieira

Universidade Federal de Minas Gerais
Departamento de Ciência da Computação
Belo Horizonte, MG, Brasil

1 Introdução

A integração de redes via satélite é um pilar fundamental da sexta geração de conectividade (6G), com o objetivo de fornecer cobertura global e ininterrupta. Constelações de satélites *Low Earth Orbit* (LEO), operando a aproximadamente 550 km de altitude, oferecem baixa latência, mas impõem o desafio de handovers frequentes — a cada 2 a 5 minutos — devido à alta velocidade orbital ($\approx 7,6$ km/s) [7].

O trabalho realizado na primeira parte deste projeto (POC I) estabeleceu uma solução baseline baseada no algoritmo REINFORCE com uma rede MLP de 32 *features*, integrada ao pipeline Hypatia + ns-3. Os resultados demonstraram que o agente treinado é capaz de reduzir em 47,1% as interrupções de conectividade em simulações de 2 horas (mais de um ciclo orbital completo), com ganho de 4,4% na latência mediana. Contudo, dois pontos de melhoria críticos foram identificados:

1. O agente realiza $2,65\times$ mais handovers que a heurística de distância mínima, sugerindo que a função de recompensa atual ($\beta = 15$) não penaliza adequadamente as trocas desnecessárias.
2. A MLP processa cada passo de tempo de forma independente, sem explorar a periodicidade orbital de ≈ 96 minutos.

Esta proposta descreve as atividades a serem realizadas na POC II, que visam superar essas limitações por meio de três eixos de investigação:

1. **Reward Shaping Multiobjetivo** — reformulação da função de recompensa para equilibrar qualidade do enlace, disponibilidade de conectividade e custo de handover, inspirada em trabalhos recentes de handover multiobjetivo em LEO [1].
2. **Memória Temporal via LSTM** — substituição da MLP por uma arquitetura recorrente capaz de capturar dependências temporais nos padrões orbitais, abordagem estudada em [2].
3. **Algoritmo PPO** — substituição do REINFORCE pelo Proximal Policy Optimization (PPO) [4], algoritmo de política mais estável e eficiente em termos de amostras.

Adicionalmente, todos os experimentos serão executados com validação estatística robusta usando múltiplas seeds, seguindo as diretrizes de [6].

2 Objetivos

2.1 Objetivo Geral

Estender e aprofundar o sistema de handover inteligente desenvolvido na POC I, investigando o impacto isolado e combinado de reward shaping multiobjetivo, memória temporal (LSTM) e do algoritmo PPO sobre as métricas de desempenho de rede em uma constelação LEO simulada de 625 satélites.

2.2 Objetivos Específicos

- **(H1 — Reward Shaping)** Avaliar se uma função de recompensa multiobjetivo, com pesagem sistemática das componentes de sinal, latência, disponibilidade e penalidade de handover, reduz o excesso de trocas sem sacrificar significativamente a disponibilidade de conexão.
- **(H2 — Temporalidade)** Verificar se uma política LSTM melhora a capacidade de antecipação orbital em relação à política MLP, especialmente antes do primeiro ciclo orbital completo (≈ 96 min).
- **(H3 — PPO)** Comparar REINFORCE e PPO em termos de convergência, estabilidade de treinamento e qualidade da política final nas configurações MLP e LSTM.
- **(Escala)** Realizar um experimento exploratório com a constelação em escala maior, motivado pelo contexto Starlink com 4.236 satélites estudado em [5].
- **(Validação)** Executar todos os experimentos com $N = 10$ seeds independentes e reportar $\mu \pm \sigma$ com intervalos de confiança de 95%, seguindo as recomendações de [6].

2.3 Contribuições Esperadas

1. Análise sistemática do trade-off entre continuidade de conexão, qualidade de enlace e frequência de handover por meio de reward shaping.
2. Demonstração empírica do benefício de memória temporal na política de handover LEO antes e ao longo do ciclo orbital.
3. Estudo de ablation comparando arquitetura (MLP vs. LSTM) e algoritmo (REINFORCE vs. PPO) de forma cruzada.
4. Framework de avaliação estatisticamente robusto e reproduzível para políticas de handover em simuladores LEO.

3 Referencial Teórico

3.1 Handover Multiobjetivo em Redes LEO

O trabalho de Song et al. [1] formula o handover como um problema de otimização multiobjetivo, balanceando simultaneamente frequência de handover, carga dos satélites, throughput e estabilidade do serviço (p. 1–2 do artigo). Os autores propõem uma nova função de recompensa combinada:

$$R = w_1 Q_{\text{signal}} + w_2 Q_{\text{latency}} + w_3 Q_{\text{availability}} - w_4 I_{\text{HO}} - w_5 \text{Load}, \quad (1)$$

onde cada w_i é um peso a ser ajustado sistematicamente. A Equação (1) serve de base para o Experimento 1 desta proposta, transformando o ajuste de β em uma investigação científica: *qual é o trade-off ótimo entre continuidade de conexão, qualidade do enlace e número de handovers?*

3.2 Arquitetura LSTM para Previsão e Handover em LEO

Fan et al. [2] propõem o uso de LSTM para prever padrões futuros de tráfego em redes LEO e, com base nessa previsão, tomar decisões proativas de handover (p. 2–4 do artigo). A arquitetura combina LSTM com atenção e Rainbow DQN para capturar o estado temporal da rede. Para este projeto, o foco está na camada recorrente como substituta da MLP:

$$[s_{t-T+1}, \dots, s_t] \xrightarrow{\text{LSTM}} h_t \xrightarrow{\pi} a_t, \quad (2)$$

onde T é o tamanho da janela temporal. Isso permite ao agente observar a trajetória orbital, e não apenas o estado instantâneo.

3.3 Mecanismo de Atenção — Transformer

Vaswani et al. [3] introduziram o Transformer, que substitui a recorrência por mecanismos de self-attention, permitindo modelar relações entre diferentes posições da sequência sem dependência temporal estrita (p. 2–3 do artigo). Para o problema de handover LEO, o agente poderia aprender quais momentos do histórico orbital são mais relevantes para a decisão atual.

3.4 Proximal Policy Optimization (PPO)

Schulman et al. [4] propõem o PPO, um algoritmo de gradiente de política que melhora a estabilidade e a eficiência de amostra do REINFORCE mediante uma

função objetivo com razão de probabilidade *clipped* (p. 1–2 do artigo):

$$L^{\text{CLIP}}(\theta) = \hat{\mathbb{E}}_t \left[\min \left(r_t(\theta) \hat{A}_t, \text{clip}(r_t(\theta), 1 - \varepsilon, 1 + \varepsilon) \hat{A}_t \right) \right], \quad (3)$$

onde $r_t(\theta) = \pi_\theta(a_t|s_t)/\pi_{\theta_{\text{old}}}(a_t|s_t)$. O PPO permite múltiplas atualizações sobre os dados coletados sem divergência da política.

3.5 Escalabilidade: Mega-constelações

Wu et al. [5] apresentam o SaTE para a constelação Starlink com 4.236 satélites, usando grafos heterogêneos e redes neurais de grafos para inferência em tempo real com latência média de 17 ms (p. 1–3 do artigo). O trabalho justifica a motivação para escalar os experimentos e contextualiza a dificuldade computacional associada.

3.6 Reprodutibilidade em Deep Reinforcement Learning

Henderson et al. [6] demonstram que resultados de Deep RL apresentam variação significativa devido ao não determinismo e às características estocásticas do treinamento, recomendando práticas rigorosas de avaliação (p. 2–5 do artigo): múltiplas seeds independentes, testes de significância, e reporte de $\mu \pm \sigma$ com IC de 95%.

4 Metodologia

4.1 Ponto de Partida: Baseline da POC I

O ponto de partida é o agente REINFORCE + MLP de 32 features treinado na POC I, avaliado no pipeline Hypatia + ns-3 com a constelação de 625 satélites. A função de recompensa atual é:

$$r_t = \text{SNR} - \alpha L_{\text{prop}} - \beta I_{\text{HO}} - \delta I_{\text{disconnect}}, \quad \beta = 15, \delta = 50. \quad (4)$$

Métricas de referência: número de handovers, interrupções, RTT mediano, UDP delivery ratio, TCP FCT e throughput.

4.2 Experimento 1 — Reward Shaping Multiobjetivo

Mantendo arquitetura MLP e algoritmo REINFORCE, substitui-se Eq. (4) pela função multiobjetivo Eq. (1). Varia-se sistematicamente:

$$\beta \in \{5, 10, 15, 25, 50, 75\}.$$

Analisa-se o trade-off entre handovers e disponibilidade. Os pesos ótimos definidos aqui serão usados nos experimentos subsequentes.

4.3 Experimento 2 — Memória Temporal com LSTM

Com a recompensa otimizada, substitui-se a MLP por uma LSTM de janela T :

$$\mathbf{S}_t = [s_{t-T+1}, \dots, s_{t-1}, s_t] \in \mathbb{R}^{T \times 32}. \quad (5)$$

Comparação: REINFORCE + MLP vs. REINFORCE + LSTM ($T \in \{10, 20\}$), nos horizontes de 20 min e 2 h.

Pergunta científica:

A memória temporal permite ao agente explorar a periodicidade orbital de ≈ 96 min e melhorar o desempenho antes do primeiro ciclo orbital completo?

4.4 Experimento 3 — Transformer como Alternativa ao LSTM

Substitui-se a LSTM por um Transformer Encoder de L camadas sobre a janela de T passos:

$$[s_{t-T+1}, \dots, s_t] \xrightarrow{\text{Transformer Encoder}} h_t \xrightarrow{\pi} a_t. \quad (6)$$

Comparação direta com os resultados do Experimento 2, avaliando desempenho e custo computacional.

4.5 Experimento 4 — Ablation: Arquitetura $\times$ Algoritmo (PPO)

Tabela 1: Matriz de ablation.

Configuração	Arquitetura	Algoritmo
Baseline (POC I)	MLP	REINFORCE
Experimento 4a	MLP	PPO
Experimento 4b	LSTM	REINFORCE
Experimento 4c	LSTM	PPO
Referência	—	Heurística dist. mínima

5 Hipóteses de Pesquisa

H1 — Reward Shaping: Uma função de recompensa multiobjetivo reduz o excesso de handovers sem sacrificar significativamente a disponibilidade de conexão.

- H2 — Temporalidade:** Uma política LSTM melhora a capacidade de antecipação em relação à MLP, especialmente antes/ao longo do primeiro ciclo orbital completo de ≈ 96 min.
- H3 — Eficiência Algorítmica:** O PPO converge mais rapidamente e produz políticas com menor variância do que o REINFORCE, em ambas as arquiteturas (MLP e LSTM).

6 Resultados Esperados

1. **Função de recompensa otimizada:** identificação dos pesos w_i que minimizam o número de handovers com perda aceitável de disponibilidade.
2. **Ganho de antecipação orbital:** demonstração de que a LSTM melhora métricas de longo prazo (2h) em relação à MLP, especialmente antes do primeiro ciclo orbital completo.
3. **Estudo de ablation:** tabela comparativa para as quatro combinações arquitetura $\times$ algoritmo, com IC de 95% e análise de significância estatística.
4. **Resultados estatísticos:** diferenças entre as diferentes abordagens.

7 Cronograma

Tabela 2: Cronograma de atividades — POC II (10 semanas).

Semana	Atividade Principal	Tarefas Detalhadas
1	Revisão bibliográfica e setup	Leitura aprofundada de [1, 2, 4, 6, 5, 3]; revisão do código da POC I; configuração do ambiente de experimentos.
2	Implementação do Exp. 1 (Reward Shaping)	Implementação da nova função de recompensa multiobjetivo (Eq. 1); definição do grid de pesos β ; primeiros treinamentos.
3	Avaliação do Exp. 1	Execução completa com o grid de pesos; análise das métricas; seleção da configuração ótima de recompensa.
4	Implementação do Exp. 2 (LSTM)	Implementação da arquitetura LSTM; janelas $T \in \{10, 20\}$; primeiros treinamentos.
5	Avaliação do Exp. 2 e início do Exp. 3 (Transformer)	Comparação MLP vs. LSTM nos horizontes de 20 min e 2 h; análise da antecipação orbital; início da implementação do Transformer.
6	Avaliação do Exp. 3 (Transformer)	Conclusão da implementação do Transformer; comparação LSTM vs. Transformer; seleção da melhor arquitetura com memória temporal.
7	Implementação e avaliação do Exp. 4 (PPO)	Implementação do PPO; execução do ablation $\{\text{MLP}, \text{LSTM}\} \times \{\text{REINFORCE}, \text{PPO}\}$; coleta das curvas de convergência.
8	Validação estatística (Exp. 5) e exploratório (Exp. 6)	Execução com $N = 10$ seeds; cálculo de $\mu \pm \sigma$ e IC 95%; experimento exploratório de escalabilidade.
9	Análise consolidada dos resultados	Geração de gráficos comparativos, tabelas e CDFs; análise do ablation; identificação das melhores configurações.
10	Escrita do relatório final	Redação da monografia (introdução, referencial teórico, metodologia, resultados e conclusão); revisão e entrega.

Referências

- [1] M. Song, J. Tian, H. Zhang, T. Xu, H. Hu e T. Zhou, “Deep Reinforcement Learning Based Multi-Objective Handover for LEO Satellite Networks,” em *2025 IEEE 101st Vehicular Technology Conference (VTC2025-Spring)*, IEEE, 2025. DOI: 10.1109/VTC2025-SPRING65109.2025.11174574. *Citadas p. 1–2.*
- [2] D. Fan, S. Zhou, J. Luo, Z. Yang e M. Zeng, “Joint Traffic Prediction and Handover Design for LEO Satellite Networks with LSTM and Attention-Enhanced Rainbow DQN,” *Electronics*, vol. 14, n. 15, p. 3040, 2025. DOI: 10.3390/electronics14153040. *Citadas p. 2–4.*
- [3] A. Vaswani, N. Shazeer, N. Parmar, J. Uszkoreit, L. Jones, A. N. Gomez, L. Kaiser e I. Polosukhin, “Attention Is All You Need,” em *Advances in Neural Information Processing Systems (NeurIPS)*, 2017. arXiv:1706.03762. *Citadas p. 2–3.*
- [4] J. Schulman, F. Wolski, P. Dhariwal, A. Radford e O. Klimov, “Proximal Policy Optimization Algorithms,” arXiv:1707.06347, OpenAI, 2017. *Citadas p. 1–2.*
- [5] H. Wu, Y. Han, M. Rajpal, Q. Zhang e J. Wang, “SaTE: Low-Latency Traffic Engineering for Satellite Networks,” em *Proceedings of the ACM SIGCOMM 2025 Conference*, SIGCOMM ’25, pp. 896–916. ACM, 2025. DOI: 10.1145/3718958.3750524. *Citadas p. 1–3.*
- [6] P. Henderson, R. Islam, P. Bachman, J. Pineau, D. Precup e D. Meger, “Deep Reinforcement Learning that Matters,” em *Proceedings of the 32nd AAAI Conference on Artificial Intelligence (AAAI-18)*, 2018. DOI: 10.1609/aaai.v32i1.11694. *Citadas p. 2–5.*
- [7] N. Mohan, A. E. Ferguson, H. Cech, R. Bose, P. R. Renatin, M. K. Marina e J. Ott, “A Multifaceted Look at Starlink Performance,” em *Proceedings of the ACM Web Conference 2024*, WWW ’24, pp. 2723–2734. ACM, 2024.