

Projeto Orientado em Computação I

Relatório Final

Otimização de Handover em Constelações de Satélites via Aprendizado por Reforço: Uma Abordagem Trace-Driven para Redes 6G

Lucas Santana do Carmo Sacramento

Orientador: Luiz Filipe Menezes Vieira

Universidade Federal de Minas Gerais
Departamento de Ciência da Computação

Belo Horizonte, MG, Brasil

Resumo

O crescimento acelerado das constelações de satélites de órbita baixa (LEO) coloca em evidência um dos problemas centrais dessas redes: o gerenciamento de handover entre estações terrestres e satélites em movimento. A heurística convencional de distância mínima, adotada por simuladores como o Hypatia, é gulosa e ignora o contexto temporal, provocando trocas desnecessárias e interrupções de conectividade. Este trabalho propõe a substituição dessa heurística por um agente de Aprendizado por Reforço (RL) baseado no algoritmo REINFORCE (Policy Gradient), capaz de antecipar a dinâmica orbital e tomar decisões proativas de handover. O agente é treinado em um ambiente de simulação orbital com 625 satélites e 100 estações terrestres, e avaliado por meio do simulador de redes ns-3 com tráfego real de TCP, UDP e ICMP. Os resultados demonstram que, em simulações de duas horas — abrangendo mais de um ciclo orbital completo —, o agente de RL reduziu em **47% o número de interrupções de conectividade** e apresentou redução de **4,4% na latência mediana** em comparação à heurística, sem degradação significativa nas métricas de desempenho de rede de curto prazo.

Palavras-chave: Satélites LEO, Handover, Aprendizado por Reforço, REINFORCE, Hypatia, ns-3, Redes de Comunicação via Satélite.

1 Introdução

O cenário de comunicações via satélite passou por uma transformação fundamental na última década. O surgimento de mega-constelações de satélites em órbita baixa (LEO — *Low Earth Orbit*), exemplificadas pelo Starlink da SpaceX com milhares de unidades em operação [1], representa uma mudança de paradigma em relação às constelações GEO tradicionais: satélites a ~550 km de altitude oferecem latência de propagação de dezenas de milissegundos — uma fração dos ~600 ms de um enlace GEO —, o que abre possibilidades reais para aplicações sensíveis à latência [2][3].

Entretanto, essa proximidade com a superfície terrestre implica um custo operacional crítico: satélites LEO completam uma órbita completa a cada ~96 minutos e permanecem visíveis a uma estação terrestre (*ground station*, GS) por apenas alguns minutos consecutivos. Por isso, cada GS precisa trocar continuamente o satélite ao qual está conectada — processo denominado **handover**. Quando essa transição é mal planejada, as consequências são imediatas: perda de pacotes de dados em trânsito, aumento de latência, variação de jitter e, no pior caso, interrupções completas de conectividade que comprometem transmissões críticas [4].

A heurística padrão adotada em plataformas de simulação como o **Hypatia** [5] é baseada em distância mínima: a estação terrestre conecta-se ao satélite mais próximo disponível no instante atual, sem qualquer consideração sobre a trajetória futura dos candidatos. Essa abordagem gulosa (*greedy*) apresenta uma limitação estrutural: ignora o fato de que um satélite ligeiramente mais distante agora pode oferecer uma janela de visibilidade significativamente mais longa, enquanto o satélite escolhido pode sair do campo de visão em poucos minutos, forçando um novo handover prematuro. Em constelações densas — onde múltiplos satélites estão simultaneamente visíveis para cada GS — essa miopia temporal resulta em taxas de handover elevadas e períodos de desconexão desnecessários.

O **Aprendizado por Reforço** (RL — *Reinforcement Learning*) oferece uma alternativa promissora a este problema. Um agente de RL pode aprender, por meio de interações repetidas com o ambiente simulado, a tomar decisões de handover que consideram não apenas o estado

presente, mas também o futuro previsível do contexto orbital. Diferentemente de abordagens supervisionadas — que exigiriam rótulos de "decisão correta" impossíveis de obter a priori —, o RL aprende a partir de uma **função de recompensa** que codifica os objetivos desejados: manter alta qualidade de sinal, minimizar interrupções e evitar trocas desnecessárias.

Este trabalho apresenta as seguintes contribuições:

1. **Modelagem do problema de handover em LEO como MDP** (*Markov Decision Process*), com espaço de estado de 32 features que inclui informação de *lookahead* orbital de dois passos à frente;
2. **Implementação e treinamento de um agente REINFORCE** integrado ao pipeline Hypatia + ns-3;
3. **Avaliação experimental dupla** com dois horizontes temporais (20 minutos e 2 horas), demonstrando que a vantagem do RL em disponibilidade de conectividade se manifesta progressivamente ao longo de ciclos orbitais;
4. **Análise quantitativa comparativa** com múltiplas métricas de rede (TCP, UDP, ping-mesh, utilização de ISL).

O restante deste artigo está organizado da seguinte forma: a Seção 2 apresenta o referencial teórico; a Seção 3 discute os trabalhos relacionados; a Seção 4 descreve a proposta; a Seção 5 detalha o setup experimental; a Seção 6 apresenta e discute os resultados; as Seções 7 e 8 trazem a conclusão e os trabalhos futuros.

2 Referencial Teórico

2.1 Constelações de Satélites LEO

Satélites em órbita baixa operam tipicamente entre 200 e 2.000 km de altitude. A constelação simulada neste trabalho adota altitude de 550 km e inclinação orbital de 53° , parâmetros representativos de operações comerciais modernas [1]. Com período orbital de ~ 96 minutos e velocidade orbital de $\sim 7,5$ km/s, cada satélite completa mais de 15 revoluções diárias ao redor da Terra.

A conectividade fim-a-fim entre estações terrestres geograficamente distantes é viabilizada pelos **ISLs** (*Inter-Satellite Links*): enlaces de comunicação entre satélites vizinhos que formam uma malha global. A topologia adotada é a **plus-grid** (grade ortogonal), em que cada satélite mantém até quatro ISLs — com o satélite anterior e o posterior na mesma órbita, e com os satélites correspondentes nas órbitas adjacentes. Isso permite o roteamento de pacotes entre qualquer par de GS via múltiplos saltos inter-satelitais, sem depender de visibilidade simultânea [5][6].

Os parâmetros orbitais são especificados no formato **TLE** (*Two-Line Element Set*), padrão internacional que descreve a posição e velocidade de objetos em órbita terrestre. Cada satélite é caracterizado por: número catalográfico, época de referência, movimento médio (revoluções/dia), excentricidade, inclinação, RAAN (*Right Ascension of Ascending Node*) e anomalia média — esta última determinando a posição inicial do satélite em sua órbita [7].

2.2 O Problema do Handover em LEO

Formalmente, o handover é o evento pelo qual uma GS substitui o satélite ao qual está conectada. Em cada instante de tempo (*time step*), cada GS deve estar conectada a exatamente um satélite dentro de seu cone de visibilidade — definido pelo ângulo de elevação mínimo (30°) e pela distância máxima do enlace GSL (*Ground-to-Satellite Link*, ~ 1.100 km para altitude de 550 km).

O problema de decisão de handover apresenta características que tornam as abordagens clássicas insuficientes [4][8]:

- **Natureza dinâmica:** o conjunto de satélites visíveis muda continuamente ao longo do tempo;
- **Dependência temporal:** a melhor decisão no instante t depende do que ocorrerá em $t+1$, $t+2$, ...;
- **Multi-objetividade:** minimizar handovers, maximizar SNR e minimizar interrupções são objetivos parcialmente conflitantes;
- **Escala:** em uma constelação de 625 satélites, múltiplos candidatos estão disponíveis simultaneamente, e a escolha incorreta tem custo acumulativo ao longo de ciclos orbitais.

2.3 Aprendizado por Reforço

O Aprendizado por Reforço modela o problema de tomada de decisão sequencial como um **MDP** (*Markov Decision Process*), definido pela tupla (S, A, P, R, γ) , onde S é o espaço de estados, A o espaço de ações, P a função de transição, R a função de recompensa e $\gamma \in [0, 1]$ o fator de desconto [9]. O objetivo do agente é aprender uma política $\pi(a|s)$ que maximize o retorno esperado acumulado:

$$G_t = r_t + \gamma \cdot r_{t+1} + \gamma^2 \cdot r_{t+2} + \dots \quad (1)$$

O algoritmo **REINFORCE** (Williams, 1992) é um método de gradiente de política (*Policy Gradient*) que atualiza diretamente os parâmetros da política na direção que aumenta a probabilidade de ações que levaram a retornos acima da média. O gradiente de política é estimado por:

$$\nabla_{\theta} J(\theta) = E[G_t \cdot \nabla_{\theta} \log \pi_{\theta}(a_t|s_t)] \quad (2)$$

A perda correspondente, minimizada durante o treinamento, é:

$$L(\theta) = -G_t \cdot \log \pi_{\theta}(a_t|s_t) \quad (3)$$

O REINFORCE é adequado para este problema por sua simplicidade de implementação, ausência de necessidade de modelo do ambiente (*model-free*) e compatibilidade natural com espaços de ação discretos (escolha de satélite entre K candidatos).

2.4 Modelagem do Sinal: Equação de Friis

A qualidade do enlace rádio entre GS e satélite é quantificada pelo **SNR** (*Signal-to-Noise Ratio*), calculado com base no modelo de propagação no espaço livre (equação de Friis). Operando na banda Ka (28 GHz):

$$FSPL = 20 \cdot \log_{10} \left(\frac{4\pi \cdot d \cdot f}{c} \right) \quad (4)$$

$$SNR = P_{tx} + G_{tx} + G_{rx} - FSPL \quad (5)$$

onde d é a distância GS-satélite em metros, $f = 28$ GHz, c é a velocidade da luz, $P_{tx} = 20$ dBm, e $G_{tx} = G_{rx} = 10$ dBi. Este modelo baseia-se exclusivamente na perda de propagação no espaço livre, desconsiderando efeitos atmosféricos como atenuação por chuva — uma simplificação adequada para o contexto simulado [4]. Satélites com maior ângulo de elevação apresentam menor distância geométrica até a GS e, conseqüentemente, maior SNR.

2.5 Ferramentas de Simulação

Hypatia [5][6] é uma plataforma de código aberto para simulação de constelações de satélites. A partir de dados TLE, calcula posições orbitais precisas a cada *time step*, determina quais satélites estão visíveis para cada GS, computa rotas de menor caminho via algoritmo de Dijkstra na topologia ISL e exporta os resultados como *dynamic state* — arquivos de encaminhamento (*fstate*) e alocação de banda (*gsl_if_bandwidth*) consumidos pelo simulador de redes.

ns-3 (*Network Simulator 3*) [6] é um simulador de redes de código aberto amplamente utilizado em pesquisa acadêmica. Neste trabalho, o ns-3 importa o *dynamic state* gerado pelo Hypatia e simula o tráfego real a nível de pacote — TCP (TcpNewReno), UDP e ICMP — sobre a topologia de satélites, permitindo medir métricas de rede como throughput, latência RTT e taxa de entrega com fidelidade de simulação de grão fino.

3 Trabalhos Relacionados

O problema de handover em redes de satélites LEO tem recebido atenção crescente com a expansão das mega-constelações. Os trabalhos relacionados podem ser organizados em cinco categorias.

Heurísticas tradicionais e benchmark. A abordagem mais comum em sistemas operacionais é a seleção por força de sinal (RSSI) ou distância mínima. O próprio Hypatia [5] implementa a heurística de distância mínima como baseline, conectando a GS ao satélite geometricamente mais próximo. Embora simples e computacionalmente eficiente, essa abordagem não considera a evolução futura da constelação, resultando em handovers potencialmente desnecessários quando um satélite mais distante oferece janela de visibilidade mais longa.

Aprendizado por Reforço aplicado a satélites. Wang et al. [9] propõem um esquema de handover baseado em Deep RL para comunicações via satélite, demonstrando que agentes treinados superam heurísticas em termos de taxa de handover e qualidade de serviço. Yang et al. [4] apresentam uma visão abrangente de redes integradas espaço-ar-terra (*Space-Air-Ground*

Integrated Networks — SAGIN), discutindo o papel do RL no gerenciamento de recursos e mobilidade nessas redes heterogêneas. Diferentemente desses trabalhos, nossa abordagem integra o agente de RL diretamente ao pipeline Hypatia+ns-3, permitindo avaliação com tráfego real a nível de pacote em vez de modelos analíticos simplificados.

Medições e caracterização de redes LEO reais. Estudos empíricos sobre o desempenho do Starlink revelam características importantes do handover em operação real. Kassem et al. [2] realizam medições multidimensionais do Starlink, documentando padrões de latência e interrupções associados a eventos de handover. Mohan et al. [3] investigam o desempenho do Starlink em contextos móveis, identificando que handovers são uma das principais fontes de variabilidade de latência. Esses trabalhos motivam a necessidade de algoritmos de handover mais sofisticados e validam os parâmetros de latência utilizados em nossa simulação (RTT mediano ~ 140 ms em 550 km de altitude).

Emulação e simulação trace-driven. O trabalho original do Hypatia [5] propõe a emulação de caminhos de redes de satélites baseada em traços orbitais reais, permitindo avaliação realista de protocolos de rede. Bhattacharjee et al. [6] estendem essa abordagem para avaliar políticas de roteamento e engenharia de tráfego em constelações LEO. O trabalho de Handley [1] analisa o impacto da constelação Starlink sobre a população de objetos em órbita baixa, fornecendo contexto sobre a escala dessas implantações. Nossa contribuição se diferencia ao introduzir um agente de RL no laço de controle do Hypatia, substituindo o módulo de decisão de handover e permitindo comparação direta via ns-3.

Engenharia de tráfego em LEO. Bhattacharjee e Singla [8] propõem o SaTE (*Satellite Traffic Engineering*), um sistema de engenharia de tráfego de baixa latência para redes de satélites, explorando a previsibilidade das trajetórias orbitais para otimizar o roteamento. Essa previsibilidade é exatamente o princípio explorado pelo *lookahead* em nossa modelagem de estado.

O presente trabalho avança sobre o estado da arte ao: (i) combinar avaliação orbital via Hypatia com simulação de rede em ns-3 com múltiplos tipos de tráfego; (ii) incorporar informação de *lookahead* orbital de dois passos à frente no estado do agente; e (iii) conduzir experimentos em dois horizontes temporais para evidenciar o efeito acumulativo do aprendizado orbital ao longo de ciclos completos.

4 Proposta do Trabalho

4.1 Visão Geral da Arquitetura

A solução proposta substitui o módulo de decisão de handover do Hypatia por um agente de RL treinado, mantendo intactos os demais componentes do pipeline de simulação. A arquitetura completa compreende cinco etapas:

1. **Dados de entrada:** arquivos TLE de 625 satélites e posições de 100 GS representando grandes cidades globais;
2. **Ambiente de RL** (*satellite_env.py*): simula o movimento orbital em Python puro, calculando visibilidade, SNR e *lookahead* para cada *time step*;
3. **Treinamento** (*train.py*): executa o algoritmo REINFORCE por 30 episódios de 1 hora cada, ajustando os pesos da rede neural;

4. **Geração do *dynamic state*** com o agente treinado: o agente toma decisões determinísticas (argmax) para gerar os arquivos *fstate* e *gsl_if_bandwidth* para 2 horas de simulação;
5. **Avaliação via ns-3**: o simulador importa o *dynamic state* do RL e o da heurística, simula o tráfego de rede e exporta as métricas de desempenho.

4.2 Modelagem como Processo de Decisão de Markov

Estado (32 features por GS): O vetor de observação de cada GS descreve os $K = 4$ satélites candidatos mais próximos visíveis. Para cada candidato $k \in \{1, \dots, 4\}$, são extraídas 8 features:

Feature	Descrição
<i>elev_k</i>	Ângulo de elevação normalizado $[0, 1]$
<i>time_remaining_k</i>	Tempo até fim de visibilidade, normalizado
<i>snr_k</i>	SNR calculado via Friis, normalizado
<i>is_current_k</i>	Flag binária: satélite k é o atualmente conectado?
<i>vis_next_k</i>	Visibilidade do candidato k no próximo <i>time step</i> (+60s)
<i>snr_next_k</i>	SNR do candidato k no próximo <i>time step</i>
<i>vis_2next_k</i>	Visibilidade do candidato k em dois <i>time steps</i> (+120s)
<i>snr_2next_k</i>	SNR do candidato k em dois <i>time steps</i>

Tabela 1: Features do estado por candidato.

O *lookahead* de dois *time steps* é a característica distintiva da modelagem: ao observar a qualidade do sinal prevista para os próximos 120 segundos, o agente pode tomar decisões proativas — conectando-se antecipadamente a um satélite que estará em posição geométrica favorável antes que o atual comece a degradar.

Ação: Escolha de um entre os $K = 4$ candidatos para o uplink da GS naquele *time step*. Um mecanismo de **action masking** garante que candidatos sem linha de visada recebem logit de -10^9 , tornando sua seleção impossível de forma determinística sem instabilidade numérica.

Função de Recompensa: A recompensa é projetada para equilibrar qualidade de sinal, custo de handover e penalização de desconexão:

$$r_t = SNR_{atual} - \alpha \cdot latencia_{propagacao} - \beta \cdot I[handover] - \delta \cdot I[desconexao] \quad (6)$$

onde α pondera a penalidade de latência física; $\beta = 15$ penaliza cada evento de handover (moderado); $\delta = 50$ penaliza desconexões totais de link (crítico). A assimetria entre β e δ força o agente a priorizar a manutenção de cobertura sobre a qualidade marginal de sinal.

4.3 Arquitetura da Rede Neural

O agente implementa uma **MLP** (*Multilayer Perceptron*) de duas camadas:

Input (32) $\rightarrow$ FC(32) $\rightarrow$ ReLU $\rightarrow$ FC(32) $\rightarrow$ ReLU $\rightarrow$ FC(4) $\rightarrow$ Softmax

- **Entrada:** 32 floats (4 candidatos $\times$ 8 features)
- **Camadas ocultas:** 2×32 neurônios com ativação ReLU

- **Saída:** distribuição de probabilidade sobre 4 ações (softmax)

Em **treinamento**, a ação é amostrada estocasticamente da distribuição, permitindo exploração do espaço de ações. Em **inferência**, a ação é selecionada deterministicamente via argmax , garantindo reprodutibilidade.

4.4 Algoritmo de Treinamento (REINFORCE)

O treinamento segue o algoritmo REINFORCE com as seguintes configurações:

Hiperparâmetro	Valor
Episódios de treinamento	30
Duração por episódio	3.600 s (1 hora)
Time step	60.000 ms
Fator de desconto γ	0,95
Taxa de aprendizado (Adam)	0,005
Número de candidatos K	4

Tabela 2: Hiperparâmetros de treinamento.

O loop de atualização por episódio segue os passos: (1) para cada *time step*, cada GS observa o estado s_t e o agente amostra a ação a_t ; (2) ao final do episódio, calculam-se os retornos descontados $G_t = \sum_{k=t}^T \gamma^{k-t} \cdot r_k$; (3) os retornos são normalizados globalmente entre todas as 100 GS, garantindo comparação justa entre GS em diferentes posições geográficas; (4) a perda $L = - \sum G_t^{norm} \cdot \log \pi_{\theta}(a_t | s_t)$ é computada e os pesos são atualizados via Adam.

4.5 Geração do *Dynamic State* com o Agente Treinado

Após o treinamento, o agente é executado em modo determinístico por 2 horas (121 *time steps* de 60s). Para cada *time step*, o grafo ISL é reconstruído com pesos de distância real usando NetworkX, e o algoritmo de Dijkstra gera as tabelas de encaminhamento. Os arquivos *fs-tate_TIMESTAMP.txt* e *gsl_if_bandwidth_TIMESTAMP.txt* resultantes são consumidos pelo ns-3 da mesma forma que os gerados pela heurística, garantindo comparação justa sob condições idênticas de simulação de rede.

5 Experimentos

5.1 Configuração da Constelação

Parâmetro	Valor
Número de satélites	625 (25 órbitas $\times$ 25/órbita)
Altitude	550 km
Inclinação orbital	53°
Período orbital	~96 minutos
Ground stations	100 (grandes cidades globais)
Distância máxima GSL	1.100.000 m
Distância máxima ISL	14.000.000 m
Data rate ISL/GSL	10 Mbps
Topologia ISL	Plus-grid (4 vizinhos/satélite)

Tabela 3: Parâmetros de simulação da constelação.

5.2 Design Experimental: Dois Horizontes Temporais

A estratégia experimental combina dois cenários complementares com propósito analítico distinto:

	A — Curta Duração	B — Longa Duração
Duração	1.200 s (~20 min)	7.200 s (2 horas)
Intervalo de time step	5.000 ms	60.000 ms
Objetivo	Desempenho de rede	Interrupções e disponibilidade
Justificativa	Métricas de rede	>1 ciclo orbital completo (~96 min)

Tabela 4: Design experimental e horizontes temporais.

O Experimento B é fundamental: em 20 minutos (Experimento A), o padrão de passagens de satélites não se repete; em 2 horas, o agente atravessa mais de um ciclo orbital, podendo aplicar sua política *lookahead* com máxima eficácia. Em ambos, comparam-se: **Heurística** (distância mínima) e **RL** (agente REINFORCE treinado).

5.3 Carga de Rede (Experimento A — ns-3)

O ns-3 simula três tipos de tráfego, cada um avaliando uma dimensão diferente do impacto do handover:

Tipo	Configuração	O que mede
TCP Flows	400 fluxos de 5 MB, TcpNewReno	Confiabilidade e throughput de transferência
UDP Bursts	120 bursts, 5 Mbps, 10s cada	QoS em tempo real (sem retransmissão)
Pingmesh	12.000 amostras, intervalo 5s	Latência RTT e disponibilidade de rota

Tabela 5: Cargas de rede avaliadas no ns-3.

TCP Flows simulam transferências de arquivos: o TCP garante entrega eventual via retransmissão, mas handovers mal gerenciados aumentam o FCT (*Flow Completion Time*) e reduzem o throughput efetivo. **UDP Bursts** simulam streaming ou telemetria: pacotes perdidos durante um handover reduzem diretamente o *delivery ratio*, sem possibilidade de recuperação. **Ping-mesh** mede continuamente o RTT entre pares de GS; aumentos indicam rotas mais longas após handovers, e perda de pings indica desconexão momentânea.

6 Resultados

6.1 Disponibilidade de Conectividade ao Longo do Tempo (Experimento B — 2 horas)

O resultado mais expressivo emerge no experimento de longa duração, que abrange mais de um ciclo orbital completo. A Tabela 1 apresenta as métricas de handover e disponibilidade.

Métrica	Heurística	RL	Δ	Melhor
Handovers totais	2.730	7.226	+164,7%	Heurística
Taxa handover/hora/GS	13,76	36,43	+164,8%	Heurística
Interrupções de conectividade	4.044	2.140	−47,1%	RL
Interrupção mediana (s)	60	60	0%	Empate
Interrupção P95 (s)	120	120	0%	Empate
RTT mediano (ms)	145,02	138,65	−4,4%	RL
RTT P95 (ms)	212,10	203,40	−4,1%	RL
Loss rate pingmesh	~0,003%	0,0%	—	RL

Tabela 6: Métricas de handover e disponibilidade (Experimento B: 2 horas).

O dado central da Tabela 1 é a redução de **47,1% no número de interrupções de conectividade** (de 4.044 para 2.140). Esse resultado evidencia o mecanismo de ação do agente: enquanto a heurística reage à perda de sinal quando um satélite já está saindo do cone de visibilidade, o agente de RL antecipa esse evento e inicia a transição quando o satélite substituto ainda está em posição favorável — o que se reflete na troca mais frequente de satélites, mas em momentos menos críticos para a continuidade do serviço.

Embora o número absoluto de handovers do RL seja 2,65 vezes maior que o da heurística, a duração mediana e o P95 das interrupções são idênticos em ambas as políticas (60s e 120s, respectivamente — correspondendo exatamente a 1 e 2 *time steps*). Isso indica que, quando uma interrupção ocorre, ela tem a mesma duração em ambos os casos; o diferencial do RL é **quantas vezes** ela ocorre ao longo do tempo.

A redução de 4,4% no RTT mediano (145,02 ms $\rightarrow$ 138,65 ms) é explicada pela tendência do agente de RL de conectar-se a satélites com maior ângulo de elevação: satélites mais altos no céu têm menor distância geométrica até a GS, resultando em menor latência de propagação de sinal — conforme a equação de Friis descrita na Seção 2.4.

Análise temporal: A vantagem do RL em interrupções se acumula progressivamente ao longo da simulação. Nos primeiros 20 minutos, a diferença é marginal (como demonstrado no Experimento A). A partir de ~96 minutos (primeiro ciclo orbital completo), o agente começa




Figura 1: Comparação no total de handovers e total de desconexões para o experimento B.

a reconhecer os padrões repetitivos de passagem de satélites e tomar decisões cada vez mais eficazes de antecipação.

6.2 Desempenho de Rede de Curto Prazo (Experimento A — 20 minutos)

O Experimento A verifica se o maior número de handovers do RL introduz degradação perceptível na qualidade de serviço.

Métrica	Heurística	RL	Melhor
Handovers totais	22	25	Heurística
Taxa handover/hora	3,31	3,59	Heurística
Interrupções (count)	1.246	1.243	RL (marginal)
Interrupção mediana (s)	85	85	Empate
Interrupção P95 (s)	165	165	Empate

Tabela 7: Handover no experimento de 20 minutos.

Métrica	Heurística	RL	Melhor
RTT mediano (ms)	140,70	140,73	Empate ($\Delta < 0,03$ ms)
RTT P95 (ms)	205,67	205,26	RL (marginal)
Loss rate geral	0,242%	0,333%	Heurística
Loss rate em handovers	0,0%	0,0%	Empate
RTT P95 em handovers (ms)	205,67	205,26	RL (marginal)

Tabela 8: Métricas de latência: Pingmesh (20 min).

Em janelas de 20 minutos, as métricas de desempenho de rede são essencialmente equivalentes entre RL e heurística em todas as dimensões avaliadas. As diferenças observadas são estatisticamente marginais: a mais expressiva é o aumento de 2% no FCT mediano (+0,16 s em




Figura 2: Comparação de distribuição de RTT entre heurística e RL no experimento de 20 min.

Métrica	Heurística	RL	Melhor
Completion rate	99,75%	99,50%	Heurística (Δ 0,25 p.p.)
Throughput médio (Mbps)	5,287	5,216	Heurística (Δ 1,3%)
Throughput P95 (Mbps)	8,518	8,417	Heurística (Δ 1,2%)
FCT mediano (s)	7,955	8,118	Heurística (Δ 2,0%)
FCT P95 (s)	12,988	12,817	RL (marginal)

Tabela 9: Métricas de TCP (20 min).

transferências de ~ 8 s) e a taxa de perda do pingmesh (0,333% vs. 0,242%), que reflete o custo dos handovers mais frequentes do RL — cada handover cria uma breve janela de vulnerabilidade para pacotes ICMP. O fato de que nenhum fluxo TCP falhou e que a taxa de entrega UDP é virtualmente idêntica (Δ 0,02 p.p.) confirma que o RL é uma substituição segura da heurística do ponto de vista de QoS de curto prazo.

6.3 Visão Unificada: A Vantagem Temporal do RL

A combinação dos dois experimentos revela um padrão coerente:

A diferença de comportamento entre os dois horizontes tem explicação física direta: o período orbital de ~ 96 minutos é o horizonte natural de repetição dos padrões de visibilidade de satélites. Em 20 minutos, o agente não tem oportunidade de demonstrar sua capacidade de antecipar padrões recorrentes — age de forma similar à heurística porque a geometria orbital ainda não completou um ciclo. A partir do primeiro ciclo completo, o agente reconhece configurações já vistas, antecipa degradações de sinal iminentes e executa handovers proativos, resultando na diferença expressiva nas interrupções de conectividade observada no Experimento B.

Esse resultado valida a hipótese central deste trabalho: **a vantagem do Aprendizado por Reforço em handover de LEO é de natureza temporal e se manifesta progressivamente ao longo de ciclos orbitais completos.**




Figura 3: CDF do Flow Completion Time para heurística e RL.

Métrica	Heurística	RL	Melhor
UDP delivery ratio	99,47%	99,45%	Empate (Δ 0,02 p.p.)
ISL util. média	0,77%	0,77%	Empate
ISL hotspot (>80%)	0,029%	0,031%	Empate

Tabela 10: Métricas de UDP e ISL (20 min).

7 Conclusão

Este trabalho apresentou e avaliou uma abordagem baseada em Aprendizado por Reforço para o problema de handover em constelações de satélites LEO. O agente REINFORCE, equipado com informação de *lookahead* orbital de dois passos à frente, foi integrado ao pipeline de simulação Hypatia+ns-3 e comparado à heurística de distância mínima em dois horizontes temporais distintos.

Os resultados demonstram que o agente de RL constitui uma substituição segura e progressivamente superior à heurística convencional:

1. **Equivalência no curto prazo:** em janelas de 20 minutos, o RL não introduz degradação significativa em nenhuma métrica de rede avaliada — throughput TCP, delivery ratio UDP e latência RTT permanecem no mesmo patamar da heurística, confirmando que o maior número de handovers não compromete a qualidade de serviço imediata.
2. **Superioridade no longo prazo:** em simulações de 2 horas — abrangendo mais de um ciclo orbital completo —, o RL demonstra reduções expressivas: **47,1% menos interrupções de conectividade** e **4,4% de redução na latência mediana**, com zero perda de pacotes no pingmesh contra 0,003% da heurística.
3. **Mecanismo verificado:** a vantagem do RL emerge da capacidade de antecipar a dinâmica orbital — conectando-se proativamente a satélites em posição favorável antes que o atual comece a degradar — em contraste com a reação tardia da heurística greedy.




Figura 4: Boxplot do throughput TCP por fluxo.

Horizonte	Comportamento do RL	Interpretação
20 minutos	Equivalente à heurística	Não prejudica a curto prazo
2 horas	−47,1% interrupções; −4,4% RTT	Periodicidade orbital; <i>lookahead</i> eficaz

Tabela 11: Síntese dos resultados por horizonte temporal.

A metodologia empregada — simulação orbital realista com Hypatia, avaliação com ns-3 via três tipos de tráfego e design experimental com dois horizontes temporais — fornece uma avaliação multidimensional rigorosa que pode ser reproduzida e estendida pela comunidade de pesquisa em redes de satélites.

8 Próximos Passos

Ajuste da função de recompensa. O agente realizou 2,65x mais handovers que a heurística, impactando marginalmente a delivery ratio UDP e o FCT TCP. Aumentar o peso da penalidade de handover (atualmente $\beta = 15$) deverá reduzir o número de trocas e melhorar essas métricas, possivelmente às custas de um leve aumento de RTT — uma troca que pode ser favorável dependendo do perfil de aplicação.

Arquiteturas com memória temporal. A MLP atual processa cada *time step* de forma independente. Arquiteturas como **LSTM** ou **Transformers** poderiam capturar dependências temporais de longo prazo nos padrões orbitais — especialmente a periodicidade de ~ 96 minutos —, potencialmente melhorando o desempenho já no início das simulações, antes do primeiro ciclo orbital completo.

Informação de carga de rede no estado. Incorporar a utilização atual dos ISLs como *feature* de observação permitiria ao agente evitar satélites cujos enlaces upstream estão congestionados,

adicionando *load awareness* à política de handover.

Algoritmos de RL mais avançados. Comparar o REINFORCE com algoritmos de maior eficiência de amostra como **PPO** (*Proximal Policy Optimization*), **DQN** (*Deep Q-Network*) ou **SAC** (*Soft Actor-Critic*), que podem convergir para políticas melhores com o mesmo número de episódios.

Validação estatística com múltiplas seeds. Para robustez estatística, os experimentos devem ser repetidos com diferentes sementes aleatórias, permitindo calcular intervalos de confiança sobre os resultados.

Escalabilidade para mega-constelações. Testar o agente em constelações com 4.000–12.000 satélites (na escala do Starlink real) é o próximo passo de validação em termos de generalização. O estado do agente mantém $K = 4$ candidatos independente do tamanho da constelação, o que sugere boa escalabilidade da política, sendo o gargalo computacional o cálculo de Dijkstra a cada *time step*.

Redução do sim-to-real gap. O ambiente de treinamento atual não modela perdas atmosféricas (relevantes em banda Ka de 28 GHz durante chuva), interferência co-canal e falhas de hardware. Adicionar modelos de ruído mais realistas aproximará o agente de condições de operação real.

Referências

- [1] Jonathan C. McDowell. The low earth orbit satellite population and impacts of the spacex starlink constellation. *The Astrophysical Journal Letters*, 892(2):L36, apr 2020.
- [2] Nitinder Mohan, Andrew E. Ferguson, Hendrik Cech, Rohan Bose, Prakita Rayyan Renatin, Mahesh K. Marina, and Jörg Ott. A multifaceted look at starlink performance. In *Proceedings of the ACM Web Conference 2024, WWW '24*, page 2723–2734, New York, NY, USA, 2024. Association for Computing Machinery.
- [3] Dominic Laniewski, Eric Lanfer, and Nils Aschenbruck. Measuring mobile starlink performance: A comprehensive look. *IEEE Open Journal of the Communications Society*, 2025.
- [4] Kai Yang, Yichen Wang, Xiaozheng Gao, Chenrui Shi, Yuting Huang, Hang Yuan, and Minwei Shi. Communications in space–air–ground integrated networks: An overview. *Space: Science & Technology*, 5:0199, 2025.
- [5] Simon Kassing, Debopam Bhattacharjee, André Baptista Águas, Jens Eirik Saethre, and Ankit Singla. Exploring the “Internet from space” with Hypatia. In *ACM IMC*, 2020.
- [6] Martin Ottens, Kai-Steffen Hielscher, and Reinhard German. Trace-driven path emulation of satellite networks using hypatia, 2025.
- [7] Vijay J0shi. Starlink satellite tle/csv dataset (april 2025). <https://www.kaggle.com/datasets/vijayj0shi/starlink-satellite-tlecsv-dataset-april-2025/data>, 2025. Version 1.
- [8] Hao Wu, Yizhan Han, Mohit Rajpal, Qizhen Zhang, and Jingxian Wang. Sate: Low-latency traffic engineering for satellite networks. In *Proceedings of the ACM SIGCOMM 2025 Conference, SIGCOMM '25*, page 896–916, New York, NY, USA, 2025. Association for Computing Machinery.
- [9] Jie Wang, Weiqing Mu, Yanan Liu, Lantu Guo, Shaofeng Zhang, and Guan Gui. Deep reinforcement learning-based satellite handover scheme for satellite communications. In *2021 13th International Conference on Wireless Communications and Signal Processing (WCSP)*, pages 1–6. IEEE, 2021.